

Descrição de imagens

PROF. CESAR HENRIQUE COMIN

Sumário


- [Descritores de imagens](#)
- [Descritores de textura - GLCM](#)
- [Descritores de textura - Local Binary Patterns](#)
- [Descritor geral - Histogram of Oriented Gradients](#)
- [Visão geral dos classificadores k-vizinhos e SVM](#)

Algumas tarefas relevantes com imagens

Classificação




Deteção de objetos



Segmentação de instâncias




Segmentação semântica



Deteção de pose



Rastreamento



Descritores de imagens

- Descritores de imagens consistem em extrair um **vetor de atributos** que caracterize uma imagem ou partes dela



Exatção de
atributos


Vetor contendo n
atributos
←→
[3.2, 1.2, 5.6, ..., 12.3]

Descritores de imagens

- Porque extrair vetores?
- Vetores de atributos representam informações semânticas sobre imagens


Descritores de imagens

- Por exemplo, se quisermos classificar imagens como "cachorro" ou "gato", não podemos, em geral, comparar os píxeis das imagens
- A imagem de um cachorro marrom em um gramado é muito mais parecida com um gato marrom em um gramado do que com um cachorro branco em uma praia




Descritores de imagens

- Descritores semânticos permitem inserir imagens em um espaço de atributos que faça sentido para a aplicação





Descritores de imagens

- Idealmente, imagens com o mesmo conteúdo semântico devem gerar vetores de atributos similares



Descritores de imagens

- Ao contrário de imagens binárias, em geral é praticamente impossível definir atributos específicos de forma manual.
- Por exemplo, quais atributos diferenciam imagens de gatos e de cachorros?



Descritores de imagens

- Para caracterizar imagens gerais, temos duas abordagens principais
 - Abordagens clássicas: definem uma série de processamentos que extraem vetores de imagens utilizando sempre o mesmo critério, independentemente dos dados analisados
 - Abordagens atuais (redes neurais): aprendem automaticamente os melhores atributos de um conjunto de dados para a realização de uma tarefa específica
 - Começaremos vendo algumas abordagens clássicas

Descritores de textura

Descritores de textura

- Vimos em outras aulas o conceito de limiarização, que consiste em segmentar objetos em imagens de acordo com o nível de intensidade dos pixels.
- Mas muitas vezes nós reconhecemos objetos não por causa da intensidade dos pixels, mas por causa da **textura** dos mesmos.




Descritores de textura


- No caso de texturas, utilizamos a informação de **como o pixel se relaciona com os seus vizinhos** para definirmos se ele pertence a determinado objeto.

Descritores de textura


No caso abaixo, pixels próximos horizontalmente possuem fortes diferenças de intensidade. Essa diferença possui menor escala na imagem da esquerda do que na da direita



No caso abaixo, há uma escala característica na qual pixels tendem a ter altas diferenças de intensidade



No caso abaixo, pixels próximos tendem a ter pouca diferença de intensidade



Gray Level Co-Occurrence Matrix (GLCM)

- Dentre os diversos descritores de textura existentes, veremos um dos mais conhecidos;
- Esse descritor se baseia na chamada Gray Level Co-Occurrence Matrix. Essa matriz descreve como é o relacionamento entre as intensidades de pixels próximos em uma imagem;
- O principal parâmetro do método é o deslocamento $D = (r, c)$ que será utilizado na criação da matriz

Gray Level Co-Occurrence Matrix (GLCM)

- Cada linha e coluna da matriz de coocorrência G representa um nível de intensidade da imagem. Portanto, se a imagem possuir 256 níveis de intensidade, a matriz G possui 256 linhas e colunas.
- Dado um valor de deslocamento $D = (r, c)$, para cada pixel na posição (i, j) da imagem, verificamos a intensidade do pixel na posição $(i + r, j + c)$
- Seja $I_r = I(i, j)$ e $I_s = I(i + r, j + c)$ as intensidades dos pixels em questão, incrementamos em 1 o respectivo elemento $G(I_r, I_s)$ da matriz de coocorrência
- Após percorrermos todos os pixels da imagem, dividimos cada elemento de G pela soma de todos os valores de G , definindo uma nova matriz de coocorrência normalizada P

Gray Level Co-Occurrence Matrix (GLCM) - Exemplo

Imagem com
intensidades no
intervalo [0,7]

0	1	5	3	2
2	0	3	7	5
6	6	5	4	4
1	0	1	1	1
2	5	2	3	2

Deslocamento utilizado:

$$D = (1,2)$$

Matriz de co-
ocorrência

	0	1	2	3	4	5	6	7
0	0	0	0	0	0	0	0	0
1	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0
4	0	0	0	0	0	0	0	0
5	0	0	0	0	0	0	0	0
6	0	0	0	0	0	0	0	0
7	0	0	0	0	0	0	0	0

Gray Level Co-Occurrence Matrix (GLCM) - Exemplo

Imagem com
intensidades no
intervalo [0,7]

0	1	5	3	2
2	0	3	7	5
6	6	5	4	4
1	0	1	1	1
2	5	2	3	2

Deslocamento utilizado:

$$D = (1,2)$$

Matriz de co-
ocorrência

	0	1	2	3	4	5	6	7
0	0	0	0	1	0	0	0	0
1	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0
4	0	0	0	0	0	0	0	0
5	0	0	0	0	0	0	0	0
6	0	0	0	0	0	0	0	0
7	0	0	0	0	0	0	0	0

Gray Level Co-Occurrence Matrix (GLCM) - Exemplo

Imagem com
intensidades no
intervalo [0,7]

0	1	5	3	2
2	0	3	7	5
6	6	5	4	4
1	0	1	1	1
2	5	2	3	2

Deslocamento utilizado:

$$D = (1,2)$$

Matriz de co-
ocorrência

	0	1	2	3	4	5	6	7
0	0	0	0	1	0	0	0	0
1	0	0	0	0	0	0	0	1
2	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0
4	0	0	0	0	0	0	0	0
5	0	0	0	0	0	0	0	0
6	0	0	0	0	0	0	0	0
7	0	0	0	0	0	0	0	0

Gray Level Co-Occurrence Matrix (GLCM) - Exemplo

Imagem com
intensidades no
intervalo [0,7]

0	1	5	3	2
2	0	3	7	5
6	6	5	4	4
1	0	1	1	1
2	5	2	3	2

Deslocamento utilizado:

$$D = (1,2)$$

Matriz de co-
ocorrência

	0	1	2	3	4	5	6	7
0	0	0	0	1	0	0	0	0
1	0	0	0	0	0	0	0	1
2	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0
4	0	0	0	0	0	0	0	0
5	0	0	0	0	0	1	0	0
6	0	0	0	0	0	0	0	0
7	0	0	0	0	0	0	0	0

Gray Level Co-Occurrence Matrix (GLCM) - Exemplo

Imagem com
intensidades no
intervalo [0,7]

0	1	5	3	2
2	0	3	7	5
6	6	5	4	4
1	0	1	1	1
2	5	2	3	2

Deslocamento utilizado:

$$D = (1,2)$$

Matriz de co-
ocorrência

	0	1	2	3	4	5	6	7
0	0	0	0	2	1	0	0	0
1	0	0	2	0	0	0	0	1
2	0	0	0	0	0	1	0	0
3	0	0	0	0	1	0	0	0
4	0	0	0	0	0	0	0	0
5	0	1	0	0	0	1	0	0
6	0	2	0	0	0	0	0	0
7	0	0	0	0	0	0	0	0

Gray Level Co-Occurrence Matrix (GLCM) - Exemplo

Imagem com
intensidades no
intervalo [0,7]

0	1	5	3	2
2	0	3	7	5
6	6	5	4	4
1	0	1	1	1
2	5	2	3	2

Deslocamento utilizado:

$$D = (1,2)$$

Matriz de co-
ocorrência

	0	1	2	3	4	5	6	7
0	0	0	0	2	1	0	0	0
1	0	0	2	0	0	0	0	1
2	0	0	0	0	0	1	0	0
3	0	0	0	0	1	0	0	0
4	0	0	0	0	0	0	0	0
5	0	1	0	0	0	1	0	0
6	0	2	0	0	0	0	0	0
7	0	0	0	0	0	0	0	0

Soma da matriz: 12

Gray Level Co-Occurrence Matrix (GLCM) - Exemplo

Imagem com
intensidades no
intervalo [0,7]

0	1	5	3	2
2	0	3	7	5
6	6	5	4	4
1	0	1	1	1
2	5	2	3	2

Deslocamento utilizado:




$$D = (1,2)$$

Matriz de co-ocorrência
normalizada

	0	1	2	3	4	5	6	7
0	0	0	0	0.17	0.08	0	0	0
1	0	0	0.17	0	0	0	0	0.08
2	0	0	0	0	0	0.08	0	0
3	0	0	0	0	0.08	0	0	0
4	0	0	0	0	0	0	0	0
5	0	0.08	0	0	0	0.08	0	0
6	0	0.17	0	0	0	0	0	0
7	0	0	0	0	0	0	0	0

Soma da matriz: 12

Exemplos de GLCMs



Gray Level Co-Occurrence Matrix - Propriedades

Tendo obtido a matriz de coocorrência, podemos calcular diversas propriedades dessa matriz. Por exemplo:

O valor p_{ij} é o elemento (i, j) da matriz de coocorrência normalizado pela soma da matriz. Ele pode ser interpretado como uma probabilidade

Nome	Fórmula
Máxima probabilidade	$\max_{i,j} p_{ij}$
Contraste	$\sum_{i=0}^{K-1} \sum_{j=0}^{K-1} (i - j)^2 p_{ij}$
Uniformidade	$\sum_{i=0}^{K-1} \sum_{j=0}^{K-1} p_{ij}^2$
Homogeneidade	$\sum_{i=0}^{K-1} \sum_{j=0}^{K-1} \frac{p_{ij}}{1 + i - j }$
Entropia	$-\sum_{i=0}^{K-1} \sum_{j=0}^{K-1} p_{ij} \log_2(p_{ij})$
Correlação	$\sum_{i=0}^{K-1} \sum_{j=0}^{K-1} \frac{(i - m_r)(j - m_c)p_{ij}}{\sigma_r \sigma_c}$


Gray Level Co-Occurrence Matrix - Propriedades

- As propriedades calculadas são, aproximadamente, invariantes à translação da imagem




Gray Level Co-Occurrence Matrix - Propriedades

- As propriedades calculadas são, aproximadamente, invariantes à translação da imagem
- As propriedades não são invariantes à rotação
 - Possível estratégia: utilizar deslocamentos em diversos ângulos e somar os valores



Gray Level Co-Occurrence Matrix - Propriedades

- As propriedades calculadas são, aproximadamente, **invariantes à translação** da imagem
- As propriedades **não são invariantes à rotação**
 - Possível estratégia: utilizar deslocamentos em diversos ângulos e somar os valores
- As propriedades **não são invariantes à escala**
 - Possível estratégia: mesmo que acima, mas utilizando diferentes distâncias de deslocamento (ex: (0, 1), (0, 5), (0, 10))




Gray Level Co-Occurrence Matrix - Propriedades

Notebook “**1 - Graylevel Co-Occurrence Matrix**”

Análise local de textura usando GLCM

- Podemos analisar a textura em diferentes regiões de uma imagem utilizando GLCM
- Para isso, uma estratégia é dividirmos a imagem em regiões, e calcularmos a GLCM e suas propriedades para cada região




Local Binary patterns (LBP)

- Outra técnica utilizada para descrever a textura de objetos
- Essa técnica possui como objetivo a classificação de imagens. Isto é, a ideia dela é definir para uma dada imagem um grande conjunto de propriedades que representem a imagem
- Tais propriedades são então utilizadas para classificação

Local Binary patterns (LBP)

- Dada uma imagem de entrada, analisamos cada pixel da imagem (exceto pixels de borda)
- Em seguida comparamos o valor do pixel central com cada vizinho. Se o pixel central for maior do que o vizinho, associamos o valor 0 com o vizinho. Caso contrário, o valor 1 é associado com o vizinho



Local Binary patterns (LBP)

- O padrão obtido representa uma sequência de 8 bits
- Vamos definir que o bit 0 é o vizinho de cima do pixel referência, e que a sequência é percorrida no sentido horário
- Com isso, podemos considerar que a sequência obtida representa um número inteiro no intervalo [0,255]

0	0	1
7	0	1
6		2
5	1	4
	1	3
		1



0	0	1	1	1	0	1	0
---	---	---	---	---	---	---	---



$$2^6 + 2^4 + 2^3 + 2^2 = 92$$

Local Binary patterns (LBP)

- Em um novo array, armazenamos o valor obtido para cada pixel

Imagem

0	1	5	3	2
2	4	3	7	5
6	7	5	4	4
1	0	1	1	1
2	5	2	3	2

Valores LBP

	92	254	0	
	0	66	226	
	255	253	255	

Local Binary patterns (LBP)

- O histograma do array obtido é calculado, utilizando 256 caixas
- Esse histograma representa 256 propriedades associadas com a imagem
- Por exemplo, o valor na caixa 5 representa o número de pixels na imagem possuindo a vizinhança 00000101. Em outras palavras, o número de pixels para os quais o pixel é menor do que o pixel ao norte e à direita, e maior do que os demais

	92	254	0	
	0	66	226	
	255	253	255	

- Os 256 valores associados a cada imagem são utilizados para classificação


Descritores gerais de imagens - HoG

Conceitos básicos do Histogram of Oriented Gradients - HOG

- O descritor Histogram of Oriented Gradients (HOG) é uma metodologia que pode ser utilizada para associar um grande número de propriedades a uma dada imagem
- As propriedades são definidas de forma automática, utilizando o ângulo do vetor gradiente obtido em diferentes regiões da imagem
- O gradiente é utilizado com o objetivo de criar um descritor que seja aproximadamente **invariante** à diferenças nas intensidade dos pixels


Conceitos básicos do Histogram of Oriented Gradients - HOG

- A imagem é dividida em células
- Histogramas dos ângulos dos vetores gradientes dos pixels são calculados para cada célula




HOG

- As células são então agrupadas em blocos (quadrado azul na imagem abaixo)
- Os histogramas das células de cada bloco são concatenados para formar $n \times ncaixas$ atributos associados com cada bloco, onde n é o número de células dentro do bloco e $ncaixas$ o número de caixas utilizado para o histograma
- Os valores são normalizados pela soma de cada bloco




HOG


- As células são então agrupadas em blocos (quadrado azul na imagem abaixo)
- Os histogramas das células de cada bloco são concatenados para formar $n \times n \times ncaixas$ atributos associados com cada bloco, onde n é o número de células dentro do bloco e $ncaixas$ o número de caixas utilizado para o histograma
- Os valores são normalizados pela soma de cada bloco
- A janela de bloco é movida, e o processo é repetido



Cálculo do HOG em uma imagem de dígito




Cálculo do HOG em uma imagem de dígito




A imagem é dividida em células de tamanho 5×5 pixels (o tamanho da célula é um parâmetro do método)

Cálculo do HOG em uma imagem de dígito




Células são agrupadas em blocos de tamanho 10×10 pixels (parâmetro do método)

Cálculo do HOG em uma imagem de dígito




- Os ângulos dos vetores gradientes são calculados para cada pixel

Cálculo do HOG em uma imagem de dígito




- Um histograma é obtido para cada célula (usualmente 9 caixas são utilizadas para o histograma)
- Os histogramas das células no bloco azul são concatenados e normalizados pela soma de todos os valores

Cálculo do HOG em uma imagem de dígito



O bloco é movido 5 pixels para a direita, e o histograma normalizado é calculado novamente

Cálculo do HOG em uma imagem de dígito




E assim por diante, até o último bloco

Cálculo do HOG em uma imagem de dígito

- Nós temos 9 blocos azuis na imagem, cada um possuindo 4×9 valores de histograma (número de células em cada bloco vezes o número de caixas utilizadas para o histograma).
- Portanto, temos 324 atributos calculados para a imagem

Cálculo do HOG em uma imagem de dígito




HOG

[0.001, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.000, 0.001, 0.052, 0.219, 0.055, 0.000, 0.000, 0.000, 0.000, 0.000, 0.009, 0.171, 0.415, 0.235, 0.066, 0.006, 0.000, 0.000, 0.006, 0.026, 0.318, 0.532, 0.532, 0.091, 0.000, 0.000, 0.000, 0.024, 0.047, 0.041, 0.248, 0.081, 0.000, 0.000, 0.000, 0.000, 0.000, 0.008, 0.247, 0.392, 0.129, 0.002, 0.003, 0.000, 0.000, 0.001, 0.115, 0.071, 0.392, 0.392, 0.016, 0.000, 0.000, 0.000, 0.002, 0.009, 0.231, 0.392, 0.392, 0.012, 0.012, 0.007, 0.000, 0.005, 0.086, 0.253, 0.216, 0.035, 0.001, 0.005, 0.003, 0.052, 0.062, 0.253, 0.182, 0.013, 0.000, 0.000, 0.050, 0.079, 0.253, 0.162, 0.244, 0.253, 0.253, 0.185, 0.092, 0.122, 0.035, 0.129, 0.068, 0.242, 0.093, 0.039, 0.167, 0.253, 0.253, 0.253, 0.253, 0.144, 0.198, 0.068, 0.219, 0.169, 0.183, 0.101, 0.001, 0.000, 0.006, 0.008, 0.092, 0.285, 0.285, 0.250, 0.062, 0.000, 0.000, 0.025, 0.020, 0.027, 0.097, 0.130, 0.257, 0.285, 0.218, 0.203, 0.030, 0.003, 0.065, 0.215, 0.285, 0.285, 0.258, 0.092, 0.209, 0.165, 0.107, 0.056, 0.329, 0.329, 0.147, 0.034, 0.000, 0.000, 0.008, 0.009, 0.099, 0.329, 0.329, 0.041, 0.022, 0.005, 0.000, 0.002, 0.027, 0.119, 0.255, 0.322, 0.262, 0.088, 0.012, 0.040, 0.109, 0.150, 0.091, 0.329, 0.329, 0.038, 0.021, 0.000, 0.000, 0.010, 0.058, 0.040, 0.170, 0.353, 0.154, 0.084, 0.021, 0.030, 0.007, 0.040, 0.004, 0.027, 0.353, 0.353, 0.283, 0.077, 0.068, 0.009, 0.024, 0.004, 0.353, 0.353, 0.097, 0.009, 0.006, 0.000, 0.000, 0.003, 0.000, 0.111, 0.353, 0.260, 0.041, 0.011, 0.001, 0.000, 0.000, 0.019, 0.010, 0.021, 0.070, 0.215, 0.266, 0.288, 0.172, 0.006, 0.170, 0.029, 0.126, 0.219, 0.151, 0.136, 0.288, 0.288, 0.288, 0.022, 0.000, 0.000, 0.000, 0.008, 0.033, 0.212, 0.181, 0.020, 0.288, 0.000, 0.000, 0.000, 0.002, 0.037, 0.220, 0.288, 0.288, 0.282, 0.218, 0.072, 0.065, 0.025, 0.015, 0.049, 0.214, 0.305, 0.230, 0.305, 0.305, 0.003, 0.003, 0.000, 0.000, 0.018, 0.128, 0.305, 0.122, 0.014, 0.000, 0.000, 0.007, 0.016, 0.125, 0.305, 0.304, 0.305, 0.163, 0.000, 0.000, 0.000, 0.000, 0.008, 0.184, 0.069, 0.452, 0.452, 0.033, 0.000, 0.002, 0.000, 0.000, 0.021, 0.004, 0.221, 0.452, 0.097, 0.014, 0.003, 0.000, 0.000, 0.003, 0.114, 0.452, 0.293, 0.003, 0.000, 0.000, 0.000, 0.000, 0.046, 0.006, 0.064, 0.079, 0.005, 0.000, 0.000, 0.000, 0.000, 0.004]

Cálculo do HOG em uma imagem de dígito

Temos 324 atributos. Podemos agora pensar que cada imagem é representada por um ponto em um espaço de 324 dimensões!

Se tivéssemos apenas 2 atributos:



Exemplo de cálculo do HOG


Notebook 2 - Histogram of Oriented Gradients

Classificação de Imagens

Temos nossas imagens caracterizadas, agora precisamos de um classificador que irá utilizar as imagens conhecidas para classificar imagens cuja classe é desconhecida


Classificador k-vizinhos

- Um dos classificadores mais simples que podemos utilizar é o k-vizinhos.
- Para um dado ponto que queremos classificar (representando uma imagem com classe desconhecida), analisamos os k pontos mais próximos (k-vizinhos).
- A classe mais frequente nos k pontos analisados é associada ao ponto desconhecido.



Classificador k-vizinhos

- Um dos classificadores mais simples que podemos utilizar é o k-vizinhos.
- Para um dado ponto que queremos classificar (representando uma imagem com classe desconhecida), analisamos os k pontos mais próximos (k-vizinhos).
- A classe mais frequente nos k pontos analisados é associada ao ponto desconhecido.




Support Vector Machine (SVM)

- Outro classificador muito utilizado em processamento de imagens é o SVM


Support Vector Machine (SVM)

Suponha que temos duas classes que são linearmente separáveis:




Support Vector Machine (SVM)

Suponha que temos duas classes que são linearmente separáveis:




Nesse caso, temos diversas possibilidades para definir a função de separação entre as classes



SVM

O classificador SVM consiste em selecionar a função de separação que maximiza a margem, definida como a distância entre a reta de decisão e o ponto mais próximo à reta



SVM

Uma das principais vantagens do SVM é a sua esparsidade


Support vectors



Apenas alguns pontos, chamados de **support vectors**, são necessários para definir a função de decisão e, portanto, para classificar novas imagens


SVM

- Para classes que não são linearmente separáveis, o chamado truque de kernel (kernel trick) é utilizado
- Essa técnica corresponde a aplicar uma transformação não-linear aos atributos, definindo um novo espaço de atributos no qual as classes são linearmente separáveis





SVM – Exemplo de kernel trick

Os pontos não são linearmente separáveis





SVM – Exemplo de kernel trick

Um novo atributo (por exemplo, a distância do ponto à origem), em conjunto com os dois atributos originais, resulta em uma distribuição de pontos que é linearmente separável



SVM – Exemplo de kernel trick

Um novo atributo (por exemplo, a distância do ponto à origem), em conjunto com os dois atributos originais, resulta em uma distribuição de pontos que é linearmente separável



Classificação de dígitos utilizando o HOG e k-vizinhos

Notebook “**3 - Classificação de dígitos utilizando HOG e k-vizinhos**”