

Segmentação de imagens


PROF. CESAR HENRIQUE COMIN

Sumário

- [Segmentação de instâncias x segmentação semântica](#)
- [Métodos clássicos de segmentação](#)
- [Segmentação utilizando clusterização k-médias](#)
- [Segmentação utilizando Modelo de Mistura de Gaussianas](#)
- [Segmentação de instâncias usando redes neurais](#)
- [Segmentação semântica usando redes neurais](#)

Segmentação de Imagens

- Segmentação semântica: particionamento de uma imagem em classes distintas



Segmentação de Imagens

- Segmentação semântica: particionamento de uma imagem em classes distintas
- Segmentação de instância: identificação de todos os píxeis pertencentes a determinados objetos de uma imagem



Segmentação de Imagens

Técnicas de segmentação podem ser divididas em três categorias principais:


- Métodos Clássicos e Otimização Matemática
- Agrupamento de pixels (Clustering) usando Aprendizado de Máquina
- Redes Neurais

Métodos Clássicos e Otimização Matemática

- Baseados em limiarização: Otsu e limiarização adaptativa
- Baseados em bordas/filtros: Magnitude do gradiente para identificação de bordas, Laplaciano para identificação de objetos circulares
- Baseados em região: Crescimento de região, Watershed
- Baseados em textura: Aplicação da GLCM em regiões de uma imagem
- Modelos deformáveis/otimização: Contornos ativos

Modelos de contorno ativo


Técnica parecida com crescimento de região, mas são impostas restrições adicionais no formato do contorno. Por exemplo, podemos crescer um contorno com a restrição de que sua curvatura máxima não ultrapasse um determinado valor.



Modelos de contorno ativo

- Um conjunto de pontos de controle evolui ao longo do tempo
- A cada iteração, os pontos de controle são modificados de forma que a seguinte energia seja minimizada:

$$E_{contorno} = E_{interna} + E_{imagem}$$



Modelos de contorno ativo

- Um conjunto de pontos de controle evolui ao longo do tempo
- A cada iteração, os pontos de controle são modificados de forma que a seguinte energia seja minimizada:

$$E_{contorno} = E_{interna} + E_{imagem}$$

$E_{interna}$ está associada com a energia interna do contorno. Usualmente, ela é definida através das derivadas do contorno (curvatura), de forma que menores valores de $E_{interna}$ levem a contornos mais suaves


E_{imagem} é associada com a imagem sendo segmentada. Por exemplo, ela pode ser inversamente proporcional a magnitude do gradiente, de tal forma que o contorno seja atraído para regiões de borda.

Segmentação com uso de Aprendizado de Máquina

- Veremos dois algoritmos importantes relacionados com agrupamento de pixels:
 - Algoritmo K-médias sobre descritores
 - Modelos de mistura de gaussianas


Segmentação utilizando o algoritmo k-médias

Clusterização k-médias




- Vamos imaginar que temos duas medidas associadas a um conjunto de objetos (ex: área e circularidade)
- Cada objeto pode ser representado como um ponto em um espaço 2D de medidas

Clusterização k-médias




- Queremos identificar as classes às quais os pontos acima pertencem. Não conhecemos a classe de nenhum ponto (isto é, não há treinamento)
- Essa atividade é chamada de aprendizado não supervisionado

Clusterização k-médias




- Escolhemos um número de sementes, nesse caso, 3 sementes ($k=3$)
- A posição inicial das sementes é escolhida aleatoriamente

Clusterização k-médias




- O espaço é particionado em três regiões
- Cada região contém os pontos que estão mais próximos da semente contida na região do que qualquer outra semente
- Esse particionamento é conhecido como tesselação de Voronoi

Clusterização k-médias




- A média das posições dos pontos pertencentes a cada região é calculada
- As sementes são reposicionadas para as posições médias calculadas

Clusterização k-médias




Uma nova partição do espaço é calculada

Clusterização k-médias




As sementes são movidas para a nova média dos pontos

Clusterização k-médias





O processo continua até que as posições das sementes não mude consideravelmente, ou até que um número de iterações seja atingido

Clusterização k-médias



Segmentação utilizando k-médias

- A clusterização k-médias pode ser utilizada para segmentar imagens
- A ideia é caracterizar pixels ou regiões da imagem utilizando um conjunto de atributos, gerando um espaço de atributos de dimensão D . Em seguida, o algoritmo k-médias é aplicado aos valores calculados.



$$\begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_D \end{bmatrix}$$

Segmentação utilizando k-médias

- Para imagens coloridas, em muitos casos podemos aplicar o k-médias diretamente nas cores da imagem
- Cada cor representa uma propriedade, então em uma imagem RGB temos um espaço 3D onde cada pixel possui uma posição específica nesse espaço

Segmentação utilizando k-médias


Exemplo de segmentação utilizando o k-médias aplicado sobre as cores. Foram consideradas 3 sementes




Segmentação utilizando k-médias – Diferentes espaços de cores

- Imagens podem ser representadas em diferentes espaços de cores

Espaço de cores RGB



Espaço de cores HSV



Segmentação utilizando k-medias – Espaço de cores $L^*a^*b^*$

- O espaço de cores $L^*a^*b^*$ é definido de forma a ser perceptualmente uniforme, isto é, uma variação Δx de uma cor corresponde a uma variação similar na forma como percebemos essa cor
 - Isso não ocorre no espaço RGB. Por exemplo, para cores bem escuras, uma variação Δx da cor pode nem mesmo ser percebida visualmente

Segmentação utilizando k-medias – Espaço de cores $L^*a^*b^*$

Cor (255, 0, 0)




Cor (200, 0, 0)




-55 de vermelho

A variação de vermelho é
percebida de forma similar
nessas imagens?

Cor (0, 0, 0)



Cor (55, 0, 0)



+55 de vermelho

Segmentação utilizando k-medias – Espaço de cores $L^*a^*b^*$


- Quando realizamos segmentação utilizando cores, utilizar o espaço de cores $L^*a^*b^*$ pode proporcionar um resultado superior ao espaço RGB
- Usualmente, utilizamos os canais a^* e b^* desse espaço de cores

Segmentação utilizando k-médias

K-médias em RGB



K-médias em L*a*b*




Segmentação utilizando k-médias

Notebook “**1 - Segmentação k-médias**”

Mistura de gaussianas


Mistura de gaussianas

- Misturas de gaussianas podem ser utilizadas para representar funções possuindo diversos picos
- Por exemplo, a curva vermelha abaixo pode ser representada como a soma de três gaussianas, cada uma tendo diferentes amplitudes e larguras



Mistura de gaussianas

Exemplo para um caso 2D, elipses representam um “corte” na gaussiana utilizada para representar o grupo




Mistura de gaussianas

Assim como feito para o k-médias, podemos definir uma metodologia para ajustar K gaussianas a um conjunto de dados.

A principal diferença entre k-médias e mistura de gaussianas é que


1. K-médias resulta em *hard clustering*, isto é, cada ponto é associado a um único cluster
2. Mistura de gaussianas resulta em *soft clustering*, isto é, temos a probabilidade de cada ponto pertencer a cada classe

Exemplo de segmentação por mistura de gaussianas



Exemplo de segmentação por mistura de gaussianas

Resultado do ajuste de três gaussianas



Exemplo de segmentação por mistura de gaussianas

Probabilidades de cada pixel pertencer a cada uma das três classes

$$P(I|\mu_1, \sigma_1)$$



$$P(I|\mu_2, \sigma_2)$$



$$P(I|\mu_3, \sigma_3)$$



Mistura de gaussianas

Notebook **“2 - Segmentação com Mistura de Gaussianas”**

Segmentação utilizando redes neurais


Segmentação utilizando redes neurais

- Redes neurais de segmentação possuem diferenças significativas entre as categorias de **segmentação de instância** e **segmentação semântica**

Segmentação de instâncias

- Em segmentação de instância, em geral modelos de detecção de objetos são adaptados para também segmentar o objeto contido em cada caixa delimitadora identificada


1. Identificação de objetos



Segmentação de instâncias

- Em segmentação de instância, em geral modelos de detecção de objetos são adaptados para também segmentar o objeto contido em cada caixa delimitadora identificada

1. Identificação de objetos



2. Geração de máscaras para cada objeto



Segmentação de instâncias

- Portanto, para segmentação de instâncias, diversos modelos populares de detecção de objetos também possuem versões para segmentação
- Alguns modelos populares:
 - YOLO e RF-DETR para segmentação em tempo real
 - Mask2Former: Acurácia máxima
 - Mask R-CNN: Modelo antigo mas ainda útil em dados desafiadores, como muito objetos próximos entre si

Segmentação de instâncias


Notebook 3 - Segmentação utilizando YOLO

Segmentação semântica

- Na segmentação semântica, modelos precisam dar um resultado para cada pixel, o que torna impossível o uso de âncoras, comum em segmentação de instâncias

Segmentação semântica

- Na segmentação semântica, modelos precisam dar um resultado para cada pixel, o que torna impossível o uso de âncoras, comum em segmentação de instâncias
- O modelo possui um codificador, assim como em classificação de imagens, e um decodificador que recebe os atributos e gera a imagem final dos rótulos



Segmentação semântica

- Segmentação semântica é particularmente popular em imagens médicas, pois muitas alterações causadas por doenças, como tumores, não possuem formas definidas
- Em geral também não há uma "borda" definida, órgãos e tecidos sofrem alterações não localizadas
- A progressão de uma doença provoca alterações contínuas, que precisam ser quantificadas

Segmentação semântica

Modelos populares de segmentação semântica:


- U-Net: Imagens médicas
- SegFormer: Imagens gerais

Segmentação semântica

- Alguns conjuntos de dados populares para o treinamento e avaliação de métodos de segmentação semântica:

Segmentação semântica

- ADE20K: 27000 imagens com 710000 objetos anotados em 150 categorias



Segmentação semântica

Cityscapes


- Anotações de cenas urbanas capturadas por veículos
- 5000 imagens com anotações precisas e 20000 imagens com anotações "grosseiras"
- 30 classes



Segmentação semântica

UAVID

- Imagens de drones de alta resolução
- 43000 objetos anotados em 420 imagens 4k
- 8 classes



Segmentação semântica

Medical Segmentation Decathlon

- 2633 Imagens 3D de diversos órgãos como cérebro, fígado e coração.
- Detecção de tumores e alterações clínicas.

